

AgentCheck · Agent 输出质检工具

跨平台 Agent 输出的统一质量门禁 —— 毫秒级全量质检 · 可插拔规则包 · 证据可解释

2026 上海开源软件应用创新大赛 · 开源 AI 工具赛道 · 作品介绍 (V1.2)

作者：李冠男 · AgentCheck 团队

一、背景与痛点

企业正在大规模把客服、运营、售后等业务交给 AI Agent，但 **Agent 输出不可信** 成为规模化上线的第一道门槛：答非所问、幻觉编造、隐私泄露、承诺赔付、该转人工却自动答复.....一次失控就可能引发投诉、赔付甚至监管风险。

- 抽检漏检**：人工抽检覆盖率通常 <5%，漏检风险长期存在；
- 平台质检锁定平台**：抖音飞鸽、淘宝等平台自带质检只能覆盖自家渠道，无法统一跨平台口径；
- 规则与模型分离难**：质检规则散落在各业务代码里，换行业等于重写；
- 成本高**：用通用大模型逐条质检，单条成本与延迟都无法支撑全量。

二、解决方案：统一质量门禁


AgentCheck 是**引擎通用、规则可插拔、裁判可替换**的 Agent 输出质检工具：对任何 Agent 的每条输出，先由**确定性规则层**毫秒级拦截（路由/隐私/合规/完整性），再由**毫秒级裁判 Jev**做语义级快判，低置信判定自动**升级人工复核**，全程输出**证据链**。



核心能力

- 毫秒级全量质检**：确定性规则 + Jev (System One 决策模型，70-500ms 判定、只判断不生成)，从“抽检”升级为“全量”，实测批量单条平均 **0.4ms** (纯规则通道)；
- 可插拔规则包**：电商客服包 (218 场景基准) 与汽车金融包共用同一引擎，仅替换 JSON 规则定义，跨行业零重写；
- 双裁判降级架构**：Jev 不可用时自动降级 LLM (DeepSeek/智谱)，未配置裁判时规则层兜底，永不静默放过；
- 置信度分级升级**：critical 违规或低置信判定 → 自动进入人工复核队列，可审计可整改；
- 证据链可解释**：每条判定附带命中词/依据与置信度，质检报告可追溯、可用于整改闭环。

三、技术架构



引擎实现

模块	职责
quality_rules.py	规则层：加载规则包 JSON，执行路由合法性 / 隐私 / 合规红线 / 完整性正则（复用 safety.py 正则体系，扩展金融承诺边界与虚构事实检测）
quality_judges.py	裁判层： JevJudge (TypeSafe System One, noul 概率判定 + 置信度) 与 LLMJudge (DeepSeek/智谱，结构化 JSON 判定) 接口化，JudgeRouter 自动降级
quality_engine.py	主流程：三通道聚合 → 维度加权得分 → 总体结论 (pass/review/fail) → needs_human_review 升级
quality_api.py	FastAPI: /check 单条 · /batch 批量统计 · /packages 规则包 · /health 引擎状态 · /feedback/* 闭环 · /insights/* 数据反哺
quality_feedback.py	反馈闭环：整改建议生成（规则/知识/提示词三类）→ 应用整改（真实写规则包 / 知识补充）→ 重检验证 → 回归用例防复发 → 留痕审计
quality_insights.py	数据反哺：人工培训课件 / 客户画像（218 场景聚合） / 复购节奏分析（演示数据集）
质检工作台	前端面板：样本输入 → 报告渲染（维度分/规则明细/证据/置信度/人工复核标记）→ 批量仪表 → 闭环整改 → 数据反哺

关键设计决策

- **为什么用 Jev**：通用 LLM 逐条判定成本与延迟无法支撑全量质检；Jev 只判断不生成，返回概率与置信度，天然适合"输出是否合规"的判定任务，官方实测相比 LLM 判定快约 7 倍、省约 30% 成本（论文：*JEV-as-a-Judge: Accept When Confident, Escalate When Unsure*）；
- **为什么保留规则层**：确定性正则零成本、零延迟、可审计，拦截高置信违规（隐私泄露、承诺赔付）绝不错放，同时降低裁判调用量；
- **为什么接口化裁判**：Jev 国内可用性尚待验证，接口化 + 降级链保证任何环境都可运行、都有产出；
- **为什么规则包 JSON 化**：业务规则与引擎代码分离，行业扩展（电商→汽车金融→医疗→政务）只写配置不写代码，可版本化、可评审；

- **为什么做闭环与数据反哺**：质检不是终点而是数据生产入口——违规证据反哺规则包（pattern 驱动加入即生效）、知识库（待发布）、培训课件与客户分析，让 AI 客服随质检持续进化，形成企业级质量飞轮。

四、应用场景与演示

场景 1：电商客服质检（内置 218 场景基准）

基于 218 个业务场景（退换退款/食品安全/订单物流等 10 个域）与 93KB 基准对话集，对 Agent 每条输出执行质检。演示样本：客户投诉“食品发霉要求退款赔偿”，Agent 若**自动回复并承诺全额退款** → 路由/合规/隐私三通道全红，**0.4–1.7ms 判定违规并升级人工**；Agent 若**正确转人工** → 全通道通过。

场景 2：汽车金融客服（可插拔规则包实例）

同一引擎加载 **汽车金融/融资租赁规则包**：承诺边界（禁保证当天放款、免息、不影响征信）、虚构事实（禁编造剩余本金/结清金额/解抵押时效）、隐私与路由合规、投诉升级。演示“保证 3 个工作日解抵押 + 虚构剩余本金 5 万”的越权承诺输出 → 立即拦截。覆盖还款咨询、提前结清、解抵押办理等客户服务场景。

场景 3：批量全量质检

一次性质检 40 条样本（20 违规 + 20 合规）：**全部正确分类**，平均 0.4ms/条，违规 100% 检出并进入人工复核队列——支撑“从抽检到全量”的质检升级。

场景 4：质检反馈闭环 + 数据反哺（持续进化）

质检发现违规后，一键生成**整改建议**（路由策略 / 隐私规则 / 合规规则 / 知识补全 / 提示词优化）→ 应用整改**真实写入规则包**（带 pattern 的新规则加入即生效，规则包版本随整改自动递增 0.1→0.3）→ **重检验证 fail→pass**（实测得分 0.00→1.00）→ 整改样本登记回归用例防复发，全程留痕可审计。


同时质检数据反哺业务：**人工培训课件**（按违规维度聚合典型案例与正确话术）、**客户画像**（218 场景聚合诉求域/风险/高频词）、**复购节奏**（质检关联客户订单 → 复购率与周期分析，演示用脱敏示例数据）。

演示视频与代码仓库

- 代码仓库：[GitHub \(公开, 见提交邮件\)](#) · 本地一键运行：**setup → start → 打开 /quality-panel.html**
- 演示视频：[见提交邮件附件链接](#)（76 秒：引擎 → 违规检出 → **闭环整改 fail→pass** → 合规样本 → 金融包 → 批量质检）
- 数据合规：全部使用合成/脱敏场景数据，无真实客户信息。

五、数据飞轮：质检 → 数据反哺 → 客服进化

质检不是终点，而是**企业客服数据的生产入口**：每一条质检判定都产出结构化证据（问题点 / 客户输入 / 路由决策 / 时间戳），这些证据持续反哺 AI 客服与人工客服，形成两个闭环共用一套证据的质量飞轮。



质检证据如何反哺（两个闭环，一套证据）

反哺对象	从质检拿到什么	产出 / 动作
AI 客服（规则闭环）	违规证据 + 命中表达	规则包自动增强（pattern 新规则加入即生效，版本随整改递增）→ 同 class 违规下次必拦 → 重检验证 fail→pass （实测 0.00→1.00）
AI 客服（知识闭环）	答非所问 / 幻觉 / 信息缺失	自动生成知识补全条目（pending_publish）→ 发布后进入检索链 → 客服回答更准确
人工客服（培训闭环）	高频违规点 + 错误→正确话术	培训课件 自动生成：违规类型统计、Top 违规表达、正确话术模板 → 补人类客服短板
运营（客户洞察闭环）	客户输入 / 诉求域 / 风险 / 关联订单	客户画像 （谁在投诉、诉求分布）→ 客服资源分配； 生命周期与复购节奏 （复购率、平均复购周期、二次购买时机）→ 关怀与营销策略

为什么这是关键差异化：平台自带质检（飞鸽等）止步于“拦一条”，我们的质检证据反哺“拦一类 → 培训一队人 → 洞察一群客户”——质检成本转化为持续进化的客服资产，这是 Agent 客服规模化运营的刚需能力。

六、创新点（技术创新维度）

创新点	价值
-----	----

Jev 毫秒级裁判接入 Agent 质检	首个将 System One 决策模型用于质检的工具；全量质检从"不可能"变"0.4ms/条"
双裁判降级链 + 规则层兜底	任何环境可运行、永不静默放过；成本可控、可解释
可插拔规则包（引擎/规则分离）	跨行业（电商→金融→医疗→政务）零重写，规则可版本化评审
跨平台统一质检口径	平台自带质检锁定平台；本工具统一多平台 Agent 输出口径（自有多平台运营实践背书）
置信度分级升级人工	低置信不硬判，升级人工复核，形成"机器初筛 + 人工终审"闭环
证据链可解释	每条判定带命中词/依据/置信度，支持整改与审计
质检反馈闭环	检出→整改建议→应用整改（pattern 规则加入即生效）→重检 fail→pass→回归防复发，规则包版本随整改进化
数据反哺飞轮	质检数据反哺知识库/培训课件/客户画像/复购分析，让客服持续进化（企业级质量飞轮）

七、开源治理与长期发展

开源治理（20%）

- 许可证：GPL-3.0（允许商用但衍生必须开源，防闭源商用；SaaS 防护可升级 AGPL-3.0，详见 docs/LICENSE_DECISION.md，第三方依赖许可齐备）；
- 工程规范：CONTRIBUTING.md / SECURITY.md / AGENTS.md 齐备，密钥运行时读取绝不落盘；
- 测试基线：**110+ 项测试**（质检引擎 12 + 反馈闭环 5 + 数据反哺 4 + 006 基线 98 项），Docker Compose 一键部署；
- 数据合规：合成/脱敏场景数据公开，隐私与安全规则内建于引擎。

长期发展（20%）

- **规则包市场**：行业规则包（医疗、政务、出海）可订阅、可贡献，形成生态；
- **平台集成**：接入 Dify/N8N/LangGraph workflow 节点，成为 Agent 链路标准质检环节；
- **本地化部署**：金融/政务私有化质检，数据不出域；
- **闭环整改**：质检报告反哺规则与提示词优化，形成"检出→整改→再检"循环；
- **数据反哺**：培训课件 / 客户画像 / 复购节奏 / 知识库增补，质检成为企业客户数据的生产入口。