

AgentCheck · Agent 输出质检工具

跨平台 Agent 输出的统一质量门禁 —— 毫秒级全量质检 · 可插拔规则包 · 证据可解释

2026 上海开源软件应用创新大赛 · 开源 AI 工具赛道 · 作品介绍 (V1.0)

一、背景与痛点

企业正在大规模把客服、运营、售后等业务交给 AI Agent，但 **Agent 输出不可信** 成为规模化上线的第一道门槛：答非所问、幻觉编造、隐私泄露、承诺赔付、该转人工却自动答复.....一次失控就可能引发投诉、赔付甚至监管风险。

- **抽检漏检**：人工抽检覆盖率通常 <5%，漏检风险长期存在；
- **平台质检锁定平台**：抖音飞鸽、淘宝等平台自带质检只能覆盖自家渠道，无法统一跨平台口径；
- **规则与模型分离难**：质检规则散落在各业务代码里，换行业等于重写；
- **成本高**：用通用大模型逐条质检，单条成本与延迟都无法支撑全量。

二、解决方案：统一质量门禁

AgentCheck 是**引擎通用、规则可插拔、裁判可替换**的 Agent 输出质检工具：对任何 Agent 的每条输出，先由**确定性规则层**毫秒级拦截（路由/隐私/合规/完整性），再由**毫秒级裁判 Jev**做语义级快判，低置信判定自动**升级人工复核**，全程输出**证据链**。

0.4 ms

批量质检单条平均耗时

218

电商客服场景基准库

2

规则包：电商客服 / 汽车
金融

3

判定通道：规则 / Jev / LLM

核心能力

1. **毫秒级全量质检**：确定性规则 + Jev (System One 决策模型, 70–500ms 判定、只判断不生成)，从"抽检"升级为"全量", 实测批量单条平均 **0.4ms** (纯规则通道)；
2. **可插拔规则包**：电商客服包 (218 场景基准) 与汽车金融包共用同一引擎，仅替换 JSON 规则定义，跨行业零重写；
3. **双裁判降级架构**：Jev 不可用时自动降级 LLM (DeepSeek/智谱)，未配置裁判时规则层兜底，永不静默放过；
4. **置信度分级升级**：critical 违规或低置信判定 → 自动进入人工复核队列，可审计可整改；
5. **证据链可解释**：每条判定附带命中词/依据与置信度，质检报告可追溯、可用于整改闭环。

三、技术架构



引擎实现

模块	职责
<code>quality_rules.py</code>	规则层：加载规则包 JSON，执行路由合法性 / 隐私 / 合规红线 / 完整性正则（复用 <code>safety.py</code> 正则体系，扩展金融合规与催收时段检测）
<code>quality_judges.py</code>	裁判层： JevJudge (TypeSafe System One, noul 概率判定 + 置信度) 与 LLMJudge (DeepSeek/智谱, 结构化 JSON 判定) 接口化，JudgeRouter 自动降级
<code>quality_engine.py</code>	主流程：三通道聚合 → 维度加权得分 → 总体结论 (pass/review/fail) → <code>needs_human_review</code> 升级
<code>quality_api.py</code>	FastAPI: <code>/check</code> 单条 · <code>/batch</code> 批量统计 · <code>/packages</code> 规则包 · <code>/health</code> 引擎状态
质检工作台	前端面板：样本输入 → 报告渲染（维度分/规则明细/证据/置信度/人工复核标记） → 批量仪表

关键设计决策

- **为什么用 Jev**：通用 LLM 逐条判定成本与延迟无法支撑全量质检；Jev 只判断不生成，返回概率与置信度，天然适合“输出是否合规”的判定任务，官方实测相比 LLM 判定快约 7 倍、省约 30% 成本（论文：*JEV-as-a-Judge: Accept When Confident, Escalate When Unsure*）；
- **为什么保留规则层**：确定性正则零成本、零延迟、可审计，拦截高置信违规（隐私泄露、承诺赔付）绝不错放，同时降低裁判调用量；
- **为什么接口化裁判**：Jev 国内可用性尚待验证，接口化 + 降级链保证任何环境都可运行、都有产出；
- **为什么规则包 JSON 化**：业务规则与引擎代码分离，行业扩展（电商→汽车金融→医疗→政务）只写配置不写代码，可版本化、可评审。

四、应用场景与演示

场景 1：电商客服质检（内置 218 场景基准）

基于 218 个业务场景（退换退款/食品安全/订单物流等 10 个域）与 93KB 基准对话集，对 Agent 每条输出执行质检。演示样本：客户投诉"食品发霉要求退款赔偿"，Agent 若**自动回复并承诺全额退款** → 路由/合规/隐私三通道全红，**0.4–1.7ms 判定违规并升级人工**；Agent 若**正确转人工** → 全通道通过。

场景 2：汽车金融客服（可插拔规则包实例）

同一引擎加载 **汽车金融规则包**：催收合规（禁非允许时段联系、禁向第三方泄露债务）、征信红线（禁承诺消除征信）、减免承诺（禁承诺减免本金/利息）、监管投诉升级。演示"减免利息 + 不上征信"违规输出 → 立即拦截。

场景 3：批量全量质检

一次性质检 40 条样本（20 违规 + 20 合规）：**全部正确分类**，平均 0.4ms/条，违规 100% 检出并进入人工复核队列 —— 支撑"从抽检到全量"的质检升级。

演示视频与代码仓库

- 代码仓库：[GitHub（公开，见提交邮件）](#) · 本地一键运行：**setup** → **start** → **打开 /quality-panel.html**
- 演示视频：[见提交邮件附件链接](#)（90 秒：引擎 → 单条质检 → 批量质检 → 规则包切换）
- 数据合规：全部使用合成/脱敏场景数据，无真实客户信息。

五、创新点（技术创新维度）

创新点	价值
Jev 毫秒级裁判接入 Agent 质检	首个将 System One 决策模型用于质检的工具；全量质检从"不可能"变"0.4ms/条"
双裁判降级链 + 规则层兜底	任何环境可运行、永不静默放过；成本可控、可解释
可插拔规则包（引擎/规则分离）	跨行业（电商→金融→医疗→政务）零重写，规则可版本化评审
跨平台统一质检口径	平台自带质检锁定平台；本工具统一多平台 Agent 输出口径（自有多平台运营实践背书）
置信度分级升级人工	低置信不硬判，升级人工复核，形成"机器初筛 + 人工终审"闭环
证据链可解释	每条判定带命中词/依据/置信度，支持整改与审计

六、开源治理与长期发展

开源治理 (20%)

- 许可证：MIT (详见 docs/LICENSE_DECISION.md, 第三方依赖许可齐备) ;
- 工程规范：CONTRIBUTING.md / SECURITY.md / AGENTS.md 齐备，密钥运行时读取绝不落盘；
- 测试基线：**110+ 项测试** (含质检引擎 12 项 + 006 基线 98 项) , Docker Compose 一键部署；
- 数据合规：合成/脱敏场景数据公开，隐私与安全规则内建于引擎。

长期发展 (20%)

- **规则包市场**：行业规则包（医疗、政务、出海）可订阅、可贡献，形成生态；
- **平台集成**：接入 Dify/N8N/LangGraph 工作流节点，成为 Agent 链路标准质检环节；
- **本地化部署**：金融/政务私有化质检，数据不出域；
- **闭环整改**：质检报告反哺规则与提示词优化，形成"检出一整改一再检"循环。